优达学城毕业项目——文本分类

2018 年 5 月 6 日

肖志铭

一、问题定义

1 项目概览

文本分类问题是自然语言处理中最常见、最经典的问题之一，相关研究最早可追溯到上世纪 50 年代，当时主要是通过专家规则（Pattern）进行分类[1]。但到了上世纪 80 年代末，人们开始越来越多地关注工程化、实用化的解决方法，很多人开始研究和关注基于大规模语料的统计机器学习方法及其在自然语言处理中的应用[2]。到了现在，机器学习已成为解决文本分类问题的主要工具，并且存在多种不同的解决思路和解决方案。本项目所要做的工作，就是基于机器学习进行文本分类，并在这个过程中做一些尝试和探索。

本项目所使用的数据集为 20 newsgroups 数据集。该数据集收集了近 20000 条新闻组文档，分为了 20 个不同主题的新闻组集合。其中一些新闻组的主题比较相似，还有一些却几乎无关。这样的特性能有效的测试文本分类方法的性能，在主题无关和主题类似两种不同情况下的分类效果。

2 问题描述

文本分类是指，使用电脑对文本集按照一定的标准进行的自动分类。具体到本文的工作，就是训练一个分类器，将新闻尽可能正确的自动分类到其所属的主题之下。在 20 newsgroups 数据集中，每条新闻对应的主题都是已知的，因此本项目中将训练基于监督学习的分类器来对文本进行分类。在此之前，一个可能更关键的问题是，如何提取到有效的文本特征，来用于监督学习分类器的训练和分类。

在本文中，将尝试使用不同的特征提取方法，分别为 tf-idf 和 word2vec；在提取到特征后，再使用合适的分类器进行文本分类；最后，对分类的结果和性能做对比分析。

3 评估指标

对于本模型的评估指标，首先需要考虑准确率。它表述了预测属于某一类的个体的数量，与这些个体中实际属于该类的数量之比。其定义如下：

$$\text{Precision} = \text{TP}/(\text{TP} + \text{FP})$$

其中，TP 代表了被正确分入该类的个体的数量，FP 代表被错误分入该类的个体的数量。

另外，还需要考虑到召回率。它表述了实际属于某一类的个体的数量，与这些个体中被正确预测的数量之比。其定义如下：

$$\text{Recall} = \text{TP}/(\text{TP} + \text{FN})$$

TP 同样代表了被正确分入该类的个体的数量，而 FN 代表被错误分出该类的个体的数量。由于需要同时考虑以上两个指标，因此使用 F1 值来进行均衡的考量。F1 值的定义如下：

$$\text{F1} = 2 * \text{precision} * \text{recall}/(\text{precision} + \text{recall})$$

其中 precision 代表了准确率，而 recall 代表了召回率。在此没有调整 precision 和 recall 的比重关系，而认为它们具有同样的重要性。

本项目中使用的数据集有多个子类别。对项目中使用到的子类别，须分别计算它们的 F1 值。并在此基础上，计算它们的宏平均值。

另外，运算时间也是需要关注的指标，过长的运算时间是不能接受的。在分类性能相差不大情况下，运算时间越短的分类器越应得到青睐。

二、问题分析

1 数据集的分析

通过 sklearn 提供的接口,可以方便的直接获取 20 newsgroups 数据集的数据。在本项目中,通过设置 categories 属性,仅使用了 comp.graphics、rec.autos、sci.electronics、sci.med、talk.politics.guns 和 talk.politics.mideast 六类新闻。统计这六类新闻的数据量，得到如下的图表和表格结果：

	comp.graphics	rec.autos	sci.electronics	sci.med	talk.politics.guns	talk.politics.mideast
训练集数量	584	594	591	594	546	564
测试集数量	389	396	393	396	364	376

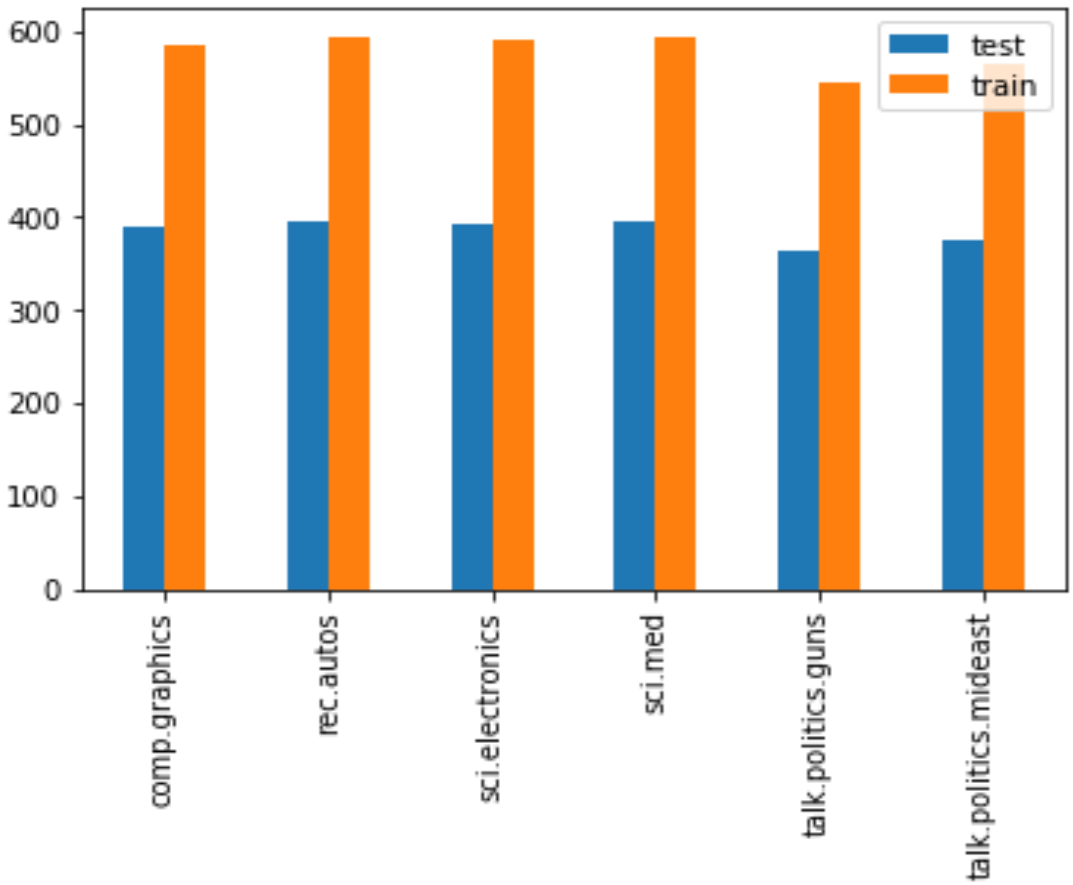

观察可知，训练集中每类新闻的数量大体相等，测试集中也是如此。同时，训练集中数量略多的类别在测试集中也数量略多，训练集中数量略少的类别在测试集中同样数量略少。这说明训练数据中不存在类别不平衡的问题，并且训练集和测试集中的数据是服从同一个分布的。

另外，在这六个类别中 sci.electronics 和 sci.med 属于同一大类，而 talk.politics.guns 和 talk.politics.mideast 也属于同一大类。这样的选择不仅能测试主题完全无关时的分类效果，还能测试主题可能相关时的分类效果。

在确定了使用的数据类别后，通过 data 属性查看数据集中的具体文本。比如训练集中的第一条文本部分如下：

```
In article <1qk5m9$pbe@news.ysu.edu> ak296@yfn.ysu.edu (John R. Daker) writes:
>>
>>I was worried about someone stealing my oil once also. I finally
>>decided to just have my drain plug welded shut. It works great !
>>I figure that when I add three or four quarts when the oil light
>>comes on every month or so that it's just as good or better than
>>the old wives tale of changing the oil AND filter every 3000 miles.
>>Works for me, I must say.
>>
>
>I did the same thing to my drain plug for the same reasons.  I was wondering
>how you filled your crankcase though as I welded my hood shut also out of fear
>that somebody might steal my air-filter.

Oh come on, Silly, all you have to do is cut a hole in your hood and
put a tube there so you can get to the oil fill hole.  What do you
think all those big air intake things are for on those hot-rod cars?
They're just for looks only...little does anyone know, they provide
access to the oil-fill hole.
```

查看该文本,注意到文章中存在着一些需要处理的地方,比如:去标点符号、修改大小写、删除停用词等。停用词即指一些词频较高，但却没有什么实际含义的词，比如英文中的 the、to、is 等。这些细节都需要在之后的数据预处理过程中得到妥善解决。

2 算法介绍

在本项目中，使用了两种不同的特征提取方法，建立了两种文本分类器。在此阶段涉及到的算法介绍如下：

(1)tf-idf：

tf-idf 特征包含了两个因子：tf 和 idf。其中，tf 统计了每个文件中每个单词出现的次数[3]。而 idf 称为逆向文件频率，表征了一个词在类别区分上的重要性，其计算公式如下：

$$\mathrm{idf_i} = \log \frac{\text{文档总数}}{\text{包含词}\mathrm{t_i}\text{的文档数} + 1}$$

将以上两个值相乘，就得到了词在某个文件中的 tf-idf 值。再将文本转化为一个包含多个 tf-idf 值的向量，从而提取到了特征。

(2)word2Vec:

word2Vec 的基本思想，是把自然语言中的每一个词都表示成一个统一意义统一维度的稠密短向量[4]。然后使用该短向量，便能轻松实现单词间的语义比较、聚类分析等工作。

要把词转化为短向量，需要使用神经网络来训练。在本项目中，使用

gensim 包完成了该步骤。在获取到所有的词向量后，还需要使用适当的方法提取表示文档的短向量。在此做了两种尝试，一种是直接求和后再求均值；另一种是基于 idf 给每个词向量赋予权重，然后再求和求均值。

对于最后的分类器，我选择了支持向量机。因为它能较好的应对高维空间，并且鲁棒性不错，适合处理当前的文本分类问题。

3 基准测试

在本项目中，我一共使用了六类新闻数据，在纯随机猜测的情况下，分类的准确率约为：1/6 ≈ 16.67%。因此如果总体准确率显著大于该数字，就说明分类器至少是有一定效果的。

但是，仅仅大于 16.67%又显然是不够的。因此本文尝试了两个不同的分类模型，一个基于词袋而另一个基于 word2Vec。其中前者更为经典和成熟，作为基准模型来使用；后者是本项目中的另一个尝试，看看是否能得到类似于前者的分类性能。

另外，是否发生过拟合也是需要关注的重点。因此在项目中会测试分类器在训练集和测试集上的性能差，查看是否存在过拟合问题。

三、方案实施

1 数据预处理

对于基准模型 tf-idf 而言，sklearn 本身已经提供了相当完整的支持。不仅不需要手工去处理分词等工作，甚至连文档向量都可以使用工具类直接生成。因此，更多的数据预处理工作是用于生成词向量模型的。在本项目中，我对数据做了如下的预处理：

(1)分词并使用正则表达式删除标点符号。

(2)删除了所有停用词。

(3)删除了分词后不包含任何字母的词。

(4)删除了单词长度只有 1 的词。

在完成以上步骤后，每个文档都被转换为了一个单词列表。然后使用 gensim 提供的方法，便可以训练词向量模型了。

2 实施过程

本项目的整个实施过程分可为以下四个步骤：

(1)基准 tf-idf 模型的训练和测试。sklearn 对此提供了比较完善的支持，通过

使用 HashVectorizer，只需几行代码便可以得到文本的 tf-idf 向量。在得到向量后，便可训练和测试分类器了。

(2)词向量模型的建立和获取词向量。在本项目中，我使用了 gensim 模块来建立词向量模型，建立模型时仅使用训练数据。整个过程也比较简单，调用对应的接口，给予预处理过的训练数据，便可得到一个词向量的模型了。在获取到词向量模型后，可以直接从模型获取到所有的词向量。

(3)根据词向量生成文档的向量。如何由词向量生成合理的文档向量，是本项目的关键问题之一。对于求和再求均值的方式，可直接计算得到文档的向量。对于第二种结合 idf 的方式，需要首先统计训练集中每个词的 idf。无论是训练集还是测试集，在生成文档向量时，都统一使用这个 idf 作为词向量的权重。

(4)训练和测试基于文档向量的文本分类器。在得到文档向量后，分类器本身的训练和测试并不是特别复杂，类似于第一个步骤即可。

3 方案改进

在整个方案的实施过程中，从基准模型到词向量，微调和改进的地方不少，主要有以下这些方面：

(1)改进基于 tf-itf 模型的分类器。我首先尝试了线性核的 SVC 分类器。在感觉到训练时间较长后，根据 sklearn 的官方文档[5]，又尝试了 LinearSVC。发现 LinearSVC 不仅大幅缩短了训练和预测的时间，而且还提升了分类性能，得到的结果如下：

	准确率	召回率	F1	训练时间	预测时间
SVC（Linear 核）	0.88	0.87	0.88	7.29 秒	4.17 秒
LinearSVC	0.90	0.90	0.90	0.13 秒	0.003 秒

可见选用 LinearSVC 分类器几乎在各个方面都得到了更好的性能。

(2)改进数据的预处理。基于数据分析阶段的大体结果，一开始我只对分词后的数据做了大小写转换、删标点符号和删停用词的处理。之后查看生成的词向量模型，发现仍存在大量的无分类意义的词。因此我又对预处理工作做了一些改进，包括：删除下划线、删除过短的词（长度小于 2）、删除纯数字。之后重新生成词向量模型，在其他条件不变的情况下，分类器的性能因此提升

了约 2%。

(3)改进词向量模型的参数。在训练词向量模型时，可以设置 min_count、sg 等参数。其中 sg 决定了词向量模型使用的算法模型：CBOW 或 Skip-gram。在本项目中 sg 设置为了 1，也就是选用 Skip-gram 模型，文本分类器的性能因此提升了至少 5%。另外，min_count 决定了一个词至少需要在训练集出现多少次，才会具有词向量，设置的过小或过大也会影响到分类器的性能。

(4)改进文档向量的生成方式。在得到词向量模型后，还需要得到每篇文档的文档向量。首先尝试了词向量相加再除以文档总词数的方式，即：

$$\text{文档向量} = \frac{\sum \text{词向量}}{\text{文本长度}}$$

之后我查看了一些论文[6]，在论文的启发下尝试将 tf、idf 与词向量结合。经过多次尝试，发现在只使用 idf 的情况下，分类器性能不错。此时生成文档向量的方式如下：

$$\text{文档向量} = \frac{\sum(\text{词向量} * \text{idf})}{\sqrt{\sum \text{idf}^2}}$$

经过这样的调整，如下表所示，分类器的性能提升了约 3%：

	准确率	召回率	F1 值
直接求均值方案	0.87	0.87	0.87
基于 idf 的方案	0.90	0.90	0.90

三、结果讨论

1 结果展示

对于基于词向量的 LinearSVC 分类器，使用 GridSearchCV 对参数 C 进行了调整。C 是一个惩罚参数，可对训练中发生的错分，调节惩罚的强度。C 过小时会引起欠拟合，而过大时会引起过拟合。最后的搜索结果为 C=2，此时分类器性能如下：

	precision	recall	f1-score	support
comp.graphics	0.85	0.90	0.87	389
rec.autos	0.91	0.92	0.91	396
sci.electronics	0.84	0.80	0.82	393
sci.med	0.92	0.90	0.91	396
talk.politics.guns	0.94	0.95	0.94	364
talk.politics.mideast	0.97	0.96	0.96	376
avg / total	0.90	0.90	0.90	2314

观察上图可知，分类器的总体 F1 值达到了 0.9。它在 sci.electronics 上表现最差，而在 talk.politics.mideast 上表现最好。对于具有相关主题的子类，比如 talk.politics.guns 和 talk.politics.mideast、sci.electronics 和 sci.med，分类器的性能并没有表现出变差的迹象。

基准模型 if-idf（features 数取 10000）和词向量方案的分类性能对比如下：

	准确率	召回率	F1 值
Tf-idf 方案	0.90	0.90	0.90
词向量方案	0.90	0.90	0.90

由表格可见，在调整了词向量模型参数和文档向量的生成方式后，后者的 F1 值同样达到了 0.9，已经有了不错的性能。

另外，基于词向量方案的分类器在测试集和训练集上的测试效果如下：

	准确率	召回率	F1 值
训练集测试结果	0.94	0.94	0.94
测试集测试结果	0.90	0.90	0.90

分类器在训练集上的效果比在测试集上的效果略好，但性能差距并不大，可以认为该分类器并不存在明显的过拟合问题。

2 思考和展望

根据本项目的实践结果，可以发现 tf-idf 模型在文本分类上依然有着可观的性能，使用起来简洁而高效。相比而言，词向量模型可以包含更为丰富的语义信息；可以避免文档向量维数过高的问题；同样有不错的文本分类性能。不过用

它来做文本分类，需要根据词向量来生成文档向量。如何生成合理的文档向量，是必须要面对的问题，本项目只是做了一些尝试，还有更多不同的方案可以选择和探索。

另外对于文本分类的问题，除了本项目中的尝试外，还有不少其他的可行方案。比如基于 Doc2Vec 的文本分类，基于 LDA 模型的文本分类等。如果想要对文本分类问题有更深入更全面的了解，还需要在以后进行更多的尝试和研究。

参考资料和文献

[1] https://www.cnblogs.com/sxron/p/7742692.html

[2] 宗成庆 《统计自然语言处理》（第 2 版） 2003

[3] https://blog.csdn.net/sangyongjia/article/details/52440063

[4] http://www.sohu.com/a/128794834_211120

[5] http://scikit-learn.org/

[6] http://www.docin.com/p-1715862349.html 基于 Word2Vec 的一种文档向量表示 （计算机科学 2016.06）